

08

Variables qualitatives

Automne 2026

Techniques d'apprentissage automatique — 420-C74-SF — gr. 10017
Spécialiste en solutions d'intelligence artificielle — M. Swawola, M.Sc.

NOUS ÉCLAIRON.
VOUS BRILLEZ.

FORMATION CONTINUE
ET SERVICES AUX ENTREPRISES



Sommaire

1. Techniques d'encodage des variables qualitatives
2. Lectures et références

Sommaire

1. Techniques d'encodage des variables qualitatives
2. Lectures et références

Variables binaires ou polytomiques (qualitatives)

- Jusqu'à présent, nous n'avons considéré que des variables explicatives **continues**. En pratique il arrive que les variables exogènes ne puissent prendre des valeurs que dans un ensemble fini de valeurs possibles et que ces valeurs n'impliquent pas un ordre entre les mesures

$$x_1^{(i)} = \begin{cases} H, & \text{si } i \text{ est un homme} \\ F, & \text{si } i \text{ est une femme} \end{cases}$$

$$x_2^{(i)} = \begin{cases} 1, & \text{si } i \text{ est une ville} \\ -1, & \text{si } i \text{ est un village} \end{cases}$$

$$x_3^{(i)} = \begin{cases} 1, & \text{si } i \text{ est à ON} \\ 0, & \text{si } i \text{ est à OFF} \end{cases}$$

- Comment utiliser ces variables en apprentissage supervisé ?

Utilisation de variables indicatrices

- On utilise des **variables indicatrices** (qui prennent la valeur 0 ou 1) pour coder les différentes modalités des variables catégorielles. Dans le cas d'une variable dichotomique, cela donne

$$x^{(i)} = \begin{cases} 1, & \text{si ...} \\ 0, & \text{sinon} \end{cases}$$

Autre codage ...

- Si ce type de codage n'est pas utilisé, les paramètres du modèle (θ) peuvent être difficiles à interpréter. Par exemple

$$x^{(i)} = \begin{cases} -5, & \text{si } i \text{ est un homme} \\ 5, & \text{si } i \text{ est une femme} \end{cases}$$

et $y^{(i)} = \theta_0 + \theta_1 x^{(i)} + \epsilon^{(i)}$, alors

$$E[y^{(i)}; i \text{ est un homme}] = \theta_0 - 5\theta_1$$

$$E[y^{(i)}; i \text{ est une femme}] = \theta_0 + 5\theta_1$$

- θ_1 représente 0.1 fois la différence entre la valeur moyenne de y pour les hommes et celle pour les femmes

Interprétation avec codage 0-1

- Si on prend

$$x^{(i)} = \begin{cases} 1, & \text{si } i \text{ est un homme} \\ 0, & \text{si } i \text{ est une femme} \end{cases}$$

alors

$$E[y^{(i)}; i \text{ est un homme}] = \theta_0 + \theta_1$$

$$E[y^{(i)}; i \text{ est une femme}] = \theta_0$$

- Maintenant θ_1 représente exactement la différence entre la valeur moyenne de y pour les hommes et celle pour les femmes

Et si une variable a plus de deux modalités ?

- Si x_i est une variable polytomique, c.-à-d. que x_i peut prendre une parmi $c \geq 2$ valeurs possibles, la façon prudente de procéder est de définir $c - 1$ **variables indicatrices**. Ainsi, si

$$x^{(i)} = \begin{cases} 1, & \text{si } i \text{ est bleu} \\ 2, & \text{si } i \text{ est rouge} \\ 3, & \text{si } i \text{ est jaune} \\ 4, & \text{si } i \text{ est vert} \end{cases}$$

alors on définit

$$x_1^{(i)} = \begin{cases} 1, & \text{si } i \text{ est bleu} \\ 0, & \text{sinon} \end{cases}$$

$$x_2^{(i)} = \begin{cases} 1, & \text{si } i \text{ est rouge} \\ 0, & \text{sinon} \end{cases}$$

$$x_3^{(i)} = \begin{cases} 1, & \text{si } i \text{ est jaune} \\ 0, & \text{sinon} \end{cases}$$

Encodage one-hot

- Un encodage **one-hot** consiste à représenter des états en utilisant pour chacun une valeur dont la représentation binaire n'a qu'un seul chiffre 1
- Exemple: les valeurs des données d'origine sont **Rouge**, **Jaune** et **Vert**. Une colonne distincte pour chaque valeur possible est créée

Couleur			
Rouge	1	0	0
Rouge	1	0	0
Jaune	0	1	0
Vert	0	0	1
Jaune	0	1	0

Question

- Comment coder les variables explicatives suivantes ?

$$x_1^{(i)} = \begin{cases} Low, & \text{si la mesure de température } i \text{ est inférieure à } 10^\circ\text{C} \\ Mid, & \text{si la mesure de température } i \text{ est entre } 10^\circ\text{C et } 30^\circ\text{C} \\ High, & \text{si la mesure de température } i \text{ est supérieure à } 30^\circ\text{C} \end{cases}$$

$$x_2^{(i)} = \begin{cases} Down, & \text{si la mesure de température } i \text{ a diminué} \\ Constant, & \text{si la mesure de température } i \text{ est restée constante} \\ Up, & \text{si la mesure de température } i \text{ a augmenté} \end{cases}$$

Sommaire

1. Techniques d'encodage des variables qualitatives
2. Lectures et références

Lectures et références

[1] Application des méthodes de régression en statistique - Université Laval