

10

Dilemme biais-variance

Automne 2026

Techniques d'apprentissage automatique — 420-C74-SF — gr. 10017
Spécialiste en solutions d'intelligence artificielle — M. Swawola, M.Sc.

**NOUS ÉCLAIRON.
VOUS BRILLEZ.**

FORMATION CONTINUE
ET SERVICES AUX ENTREPRISES




Sommaire

1. Généralisation
2. Diagnostic du biais et de la variance
3. Comment adresser le surapprentissage ?
4. Lectures et références

Sommaire

1. Généralisation
2. Diagnostic du biais et de la variance
3. Comment adresser le surapprentissage ?
4. Lectures et références

Généralisation




Quelle est la performance du modèle sur des données de production ?

Définition du surapprentissage


- Lorsque le nombre de variables explicatives est trop élevé, le modèle appris peut représenter le jeu d'entraînement de manière quasi parfaite ($J(\theta) \approx 0$) mais échouer à **généraliser** sur des nouvelles données
- Le **surapprentissage** est souvent la cause principale de performances moindre des modèles sur les données de production

En régression linéaire




$$\theta_0 + \theta_1 x$$

Sous-apprentissage
(underfitting)
Biais élevé



$$\theta_0 + \theta_1 x + \theta_2 x^2$$


Compromis



$$\theta_0 + \theta_1 x + \theta_2 x^2 + \dots + \theta_8 x^8$$


Surapprentissage
(overfitting)
Variance élevée

En régression logistique




$$g(\theta_0 + \theta_1 x)$$

**Sous-apprentissage /
underfitting**
Biais élevé



$$g(\theta_0 + \theta_1 x + \theta_2 x^2)$$


Compromis



$$g(\theta_0 + \theta_1 x + \theta_2 x^2 + \dots + \theta_7 x^7)$$

**Surapprentissage
(overfitting)**
Variance élevée

Le dilemme (ou compromis) biais-variance



Question

- **Considérons une tâche de diagnostic médical consistant en la classification de tumeurs dans les catégories maligne ou bénigne. Un surapprentissage signifie alors que le modèle ...**
 - A. réalise des prédictions précises sur le jeu d'entraînement et généralise bien sur des nouvelles données
 - B. ne réalise pas de bonnes prédictions sur le jeu d'entraînement, mais généralise bien sur des nouvelles données
 - C. réalise des prédictions précises sur le jeu d'entraînement mais ne généralise pas bien sur des nouvelles données
 - D. ne réalise pas de bonnes prédictions sur le jeu d'entraînement et ne généralise pas bien sur des nouvelles données

Sommaire

1. Généralisation
2. Diagnostic du biais et de la variance
3. Comment adresser le surapprentissage ?
4. Lectures et références


Diagnostic à l'aide du jeu de validation

- Habituellement, un modèle est **évalué** sur un **jeu de validation** (méthodologie **hold-out**)
- En apprentissage supervisé, les jeux de données sont souvent séparés en jeux d'**entraînement**, de **validation** et de **test** (sera vu plus en détails au prochain chapitre)



- Le diagnostic du biais ou de la variance peut ainsi être réalisé à l'aide des **courbes de validation et d'entraînement**
- Avec scikit-learn
`sklearn.model_selection.train_test_split(*arrays, **options)`

Courbes de validation



- Entraînement d'un modèle en augmentant graduellement sa complexité
- **Le meilleur modèle est obtenu en trouvant le compromis biais-variance**

Courbes d'apprentissage



- Entraînement d'un modèle en augmentant graduellement la quantité de données
- Mesure du **gap**
 - grand = variance élevée, biais faible
 - petit = variance faible, biais élevé

Sommaire

1. Généralisation
2. Diagnostic du biais et de la variance
3. Comment adresser le surapprentissage ?
4. Lectures et références

Comment adresser le surapprentissage ?

- **Réduire le nombre de variables explicatives manuellement ou par méthodes de sélection**

Cette approche consiste à identifier un sous-ensemble des n variables explicatives et entraîner un modèle sur ce sous-ensemble

- **Régularisation**

Les n variables explicatives restent utilisées par le modèle, mais les valeurs des paramètres θ_j sont réduites, certaines éventuellement jusqu'à zéro, réalisant ainsi une sélection des variables explicatives. Fonctionne très bien lorsque le nombre de variables explicatives est grand

- **Réduction de dimension (ACP)**

Cette approche consiste à réaliser une projection des n variables explicatives sur un sous-espace de dimension $M < n$. Les M projections seront alors utilisées comme “nouvelles” variables explicatives. Cet algorithme sera étudié lors du cours d'apprentissage non-supervisé

Sommaire

1. Généralisation
2. Diagnostic
3. Comment adresser le surapprentissage ?
4. Lectures et références

Lectures et références

[1] CS229: Machine Learning - Stanford University

[2] Introduction to Statistical Learning with Applications in R

[3] Cours “Évaluation des modèles appris”, Patrick Dallaire, CRDM