

13

Algorithme des K plus proches voisins

Automne 2026

Techniques d'apprentissage automatique — 420-C74-SF — gr. 10017
Spécialiste en solutions d'intelligence artificielle — M. Swawola, M.Sc.

**NOUS ÉCLAIRONS.
VOUS BRILLENZ.**

FORMATION CONTINUE
ET SERVICES AUX ENTREPRISES



Sommaire

1. Algorithme des K plus proches voisins
2. Choix du nombre de voisins K
3. Fléau de la dimension
4. Lectures et références


Sommaire

1. Algorithme des K plus proches voisins
2. Choix du nombre de voisins K
3. Fléau de la dimension
4. Lectures et références

Algorithme des K plus proches voisins


- Les régressions linéaire et logistique sont des **modèles paramétriques**
 - Avantage: interprétation des paramètres
 - Désavantage: supposition sur la forme de h
 - Par exemple, si on assume une relation linéaire entre X et y , mais que la relation ne l'est pas, les performances seront basses. Le **biais** sera alors élevé
- **Méthodes non paramétriques**
 - Avantages: pas de supposition sur la forme de h , méthode extrêmement flexible
 - Désavantages: **fléau de la dimension**, aucune interprétation, "scaling" difficile
 - **K plus proches voisins / K-nearest neighbors (KNN)**

KNN et régression





KNN et régression

- Étant donnée une valeur de K et un point $x^{(0)}$, la **régression KNN** identifie les K observations les plus proches de $x^{(0)}$ dans le voisinage $\mathcal{N}^{(0)}$ et estime $h(x^{(0)})$ comme la moyenne de toutes les observations dans ce voisinage



$$h(x^{(0)}) = \frac{1}{K} \sum_{x^{(i)} \in \mathcal{N}^{(0)}} y^{(i)}$$

KNN et régression



Tracés de $h(x)$ pour une régression KNN sur des données à une seule dimension (100 observations). Le véritable modèle est représenté par la ligne noire


KNN et régression

```
class sklearn.neighbors.KNeighborsRegressor(  
    n_neighbors=5,  
    weights='uniform',  
    algorithm='auto',  
    leaf_size=30,  
    p=2,  
    metric='minkowski',  
    metric_params=None,  
    n_jobs=None,  
    **kwargs)
```

■ Exemple


```
>>> X = [[0], [1], [2], [3]]  
>>> y = [0, 0, 1, 1]  
>>> from sklearn.neighbors import  
KNeighborsRegressor  
>>> neigh = KNeighborsRegressor(n_neighbors=2)  
>>> neigh.fit(X, y)  
KNeighborsRegressor(...)  
>>> print(neigh.predict([[1.5]]))  
[0.5]
```

KNN et classification




KNN et classification

- Étant donnée une valeur de K et un point $x^{(0)}$, la **classification KNN** identifie les K observations les plus proches de $x^{(0)}$ dans le voisinage $\mathcal{N}^{(0)}$ et estime $h(x^{(0)})$ comme la fraction des observations de la même classe que $x^{(0)}$



$$h(x^{(0)}) = P(Y = j | X = x^{(0)}) = \frac{1}{K} \sum_{x^{(i)} \in \mathcal{N}^{(0)}} I(y^{(i)} = j)$$

KNN et classification



La ligne noire indique la frontière de décision de l'algorithme KNN avec $K = 10$. La véritable frontière de décision est représentée par la ligne pointillée mauve

KNN et classification

```
class sklearn.neighbors.KNeighborsClassifier(  
    n_neighbors=5,  
    weights='uniform',  
    algorithm='auto',  
    leaf_size=30,  
    p=2,  
    metric='minkowski',  
    metric_params=None,  
    n_jobs=None,  
    **kwargs)
```


■ Exemple

```
>>> X = [[0], [1], [2], [3]]  
>>> y = [0, 0, 1, 1]  
>>> from sklearn.neighbors import  
KNeighborsClassifier  
>>> neigh = KNeighborsClassifier(n_neighbors=3)  
>>> neigh.fit(X, y)  
KNeighborsClassifier(...)  
>>> print(neigh.predict([[1.1]]))  
[0]  
>>> print(neigh.predict_proba([[0.9]]))  
[[0.66666667 0.33333333]]
```

Question

- Soit l'exemple suivant. Que vaut $P(Y = 1 \mid X = x^{(0)})$?

$x \rightarrow 1$
 $o \rightarrow 0$



Question

- L'algorithme KNN requiert-il une mise à l'échelle (standardisation, normalisation, ...) ?

Sommaire

1. Algorithme des K plus proches voisins
2. Choix du nombre de voisins K
3. Fléau de la dimension
4. Lectures et références

Question

- Selon vous, K est-il un paramètre ou un hyperparamètre ?



Réponse

- Selon vous, K est-il un paramètre ou un hyperparamètre ?
→ K est un hyperparamètre

Choix du nombre de voisins K



- En général, le choix de la valeur de K sera fixée par le **compromis biais-variance**
- Une petite valeur pour K fournit le modèle le plus flexible, avec **biais faible** mais une **variance élevée**. Cette variance est due au fait que la prédiction dans une région donnée dépend de peu d'observations
- Des valeurs plus élevées de K fournissent un modèle plus "lisse" et moins variable, soit un **biais élevé** mais une **variance faible**. La prédiction dans une région est une moyenne (régression) ou une proportion (classification) de plusieurs points. Ainsi, changer une observation a un effet moindre

Choix du nombre de voisins K



Pour des données **légèrement** non linéaires, sont représentés le MSE sur le jeu de test (ligne pointillée) et KNN avec différentes valeurs de $1/K$ (en vert)


Choix du nombre de voisins K




Pour des données **fortement** non linéaires, sont représentés le MSE sur le jeu de test (ligne pointillée) et KNN avec différentes valeurs de $1/K$ (en vert)

Choix du nombre de voisins K

KNN: K=1




KNN: K=100




Comparaison de la frontière de décision avec KNN (ligne noire) pour $K = 1$ et $K = 100$. Avec $K = 1$, la frontière de décision est beaucoup trop flexible, tandis qu'elle ne l'est pas suffisamment pour $K = 100$

Choix du nombre de voisins K




K=100




K=1

Erreur d'entraînement du classificateur KNN (en bleu) et erreur sur le test (en orange), en fonction de $1/K$. La ligne noire représente l'erreur de Bayes, c'est-à-dire l'erreur "imbattable"




Question

- Quelle figure montre une variance trop élevée ?




KNN: K=1



KNN: K=100

Sommaire


1. Algorithme des K plus proches voisins
2. Choix du nombre de voisins K
3. Fléau de la dimension
4. Lectures et références



Interstellar, 2014


Question

- Soit le carré de suivant. Calculer la proportion de la surface occupée par la bordure périphérique dont l'épaisseur représente 1% de la taille



Question



- Soit le cube suivant. Selon la même procédure que pour le précédent quiz, calculer la proportion du volume périphérique (1%)



Question


- Considérons maintenant la généralisation du quiz précédent à un hypercube de dimension n (cube à n dimensions). Lorsque n augmente, comment évolue la proportion de l'hypervolume occupé par la périphérie (1%) ?

Fléau de la dimension




Augmentation du volume représenté par le voisinage à mesure que le nombre de variables explicatives p augmente

Fléau de la dimension



MSE pour la régression linéaire (en noir pointillés) et KNN (en vert) lorsque le nombre de variables augmente. Les performances de la régression linéaire se détériorent lentement en présence des variables supplémentaires, tandis que les performances de KNN se dégradent beaucoup plus rapidement lorsque le nombre de variables augmente

Fléau de la dimension



MSE pour la régression linéaire (en noir pointillés) et KNN (en vert) lorsque le nombre de variables augmente. Les performances de la régression linéaire se détériorent lentement en présence des variables supplémentaires, tandis que les performances de KNN se dégradent beaucoup plus rapidement lorsque le nombre de variables augmente

Sommaire

1. Algorithme des K plus proches voisins
2. Choix du nombre de voisins K
3. Fléau de la dimension
4. Lectures et références

Lectures et références

[1] Introduction to Statistical Learning with Applications in R