

14

Arbres de décision

Automne 2026

Techniques d'apprentissage automatique — 420-C74-SF — gr. 10017
Spécialiste en solutions d'intelligence artificielle — M. Swawola, M.Sc.

NOUS ÉCLAIRON.
VOUS BRILLEZ.

FORMATION CONTINUE
ET SERVICES AUX ENTREPRISES



Sommaire

1. Introduction
2. Arbres de régression
3. Arbres de classification
4. Forces et faiblesses
5. Lectures et références


Sommaire

1. Introduction
2. Arbres de régression
3. Arbres de classification
4. Forces et faiblesses
5. Lectures et références

Arbres de décision

Très populaires en **apprentissage automatique** et en **fouille de données**

Inventés au milieu des années quatre-vingt par **Leo Breiman & Jerome H. Friedman**





Les arbres de décision sont applicables
aux problèmes de **régression** et de **classification**

L. Breiman, J. Friedman, R. Olshen, and C. Stone


“Classification And Regression Trees”, Wadsworth, Belmont, CA, 1984

ISBN-13: 978-0412048418

Arbres de régression

Prédiction d'une réponse **quantitative**


Exemple: salaire des joueurs de baseball de la ligue majeure



Arbres de classification

Prédiction d'une réponse **qualitative**

Exemple: présence ou absence d'une pathologie cardiaque (AHD¹)




1 - AHD = Alveolar Hydatid Disease

En quoi consiste un arbre de décision ?

Partitionnement ou **segmentation** de l'espace des prédicteurs en un certain nombre de **régions**

Ce partitionnement est réalisé à l'aide de règles de séparation pouvant être représentées sous forme d'un **arbre** (de décision)





Sommaire

1. Introduction
2. Arbres de régression
3. Arbres de classification
4. Forces et faiblesses
5. Lectures et références

Exemple


Jeu de données Hitters (baseball)



La **prédiction** pour chaque observation appartenant à la région R_j est la moyenne des réponses de la région R_j

Terminologie


Nœuds internes ou intérieurs



Nœuds terminaux ou feuilles ou régions


Question

- Considérons l'arbre de décision précédent. Quelle est selon vous la variable explicative la plus significative?



Interprétation

Le nombre d'années d'expérience est la variable explicative la plus importante dans la détermination du salaire




Parmi les joueurs expérimentés, le nombre de **Hits** réalisés affecte directement le salaire

Pour les joueurs moins expérimentés, le nombre de **Hits** réalisés a peu d'influence sur le salaire




Construction de l'arbre de régression

L'espace des prédicteurs est divisé en J régions rectangulaires, ou **boîtes**, distinctes et non chevauchantes $R_1, R_2, \dots, R_J$




Construction de l'arbre de régression

En pratique, il est impossible (car incalculable) de considérer l'ensemble des J partitions possibles de l'espace de prédicteurs



→ **Partitionnement binaire récursif**
(recursive binary splitting)

Construction de l'arbre de régression



On choisit à chaque étape la variable explicative qui réalise **le meilleur partage** de l'ensemble des observations (**glouton / greedy**)


→ **Somme des carrés des résidus (RSS)**

Régions $R_1, R_2, \dots, R_J$ qui minimisent la **RSS**

$$\sum_{j=1}^J \sum_{i \in R_j} (y^{(i)} - \hat{y}_{R_j})^2$$

**moyenne des réponses des
observations à l'intérieur de la
boîte j**

Construction de l'arbre de régression



Le processus continue jusqu'à l'atteinte d'un **critère d'arrêt**


Par exemple, le processus peut continuer jusqu'à ce que toutes les régions contiennent moins de cinq observations ou bien jusqu'à une profondeur donnée

Pour résumer ...

Pour résumer ...


1

On choisit une variable explicative x_j et un point de séparation s tels que la segmentation de l'espace des prédicteurs en régions $\{x \mid x_j < s\}$ et $\{x \mid x_j > s\}$ entraîne la réduction la plus grande de RSS




Pour résumer ...


1 On choisit une variable explicative x_j et un point de séparation s tels que la segmentation de l'espace des prédicteurs en régions $\{x \mid x_j < s\}$ et $\{x \mid x_j > s\}$ entraîne la réduction la plus grande de RSS



2 On répète le processus en choisissant une variable explicative x_j et un point de séparation s tels que la segmentation entraîne la réduction la plus grande de RSS




Prédictions



prédiction obtenue en calculant la moyenne des réponses des observations d'entraînement appartenant à la région R_j

$$y^{\text{test}} = \frac{1}{m_j} \sum_{i \in R_j} y^{(i)}$$

Question



Que vaut le **RSS** lorsque l'on répète le partitionnement jusqu'à l'obtention d'une seule observation par région ?


→ **RSS = 0**

Quel est le phénomène correspondant ?


→ **Surapprentissage**

Compromis biais / variance


Un arbre de décision plus petit ayant un nombre de nœuds internes plus bas (et donc moins de régions $R_1, R_2, \dots, R_J$) peut produire une **variance plus faible** et une meilleure interprétation au détriment d'un **biais légèrement plus élevé**



ARBRE A




ARBRE B



Élagage

La technique de l'**élagage** (pruning) consiste à construire un arbre T_0 très grand et élaguer ensuite celui-ci de manière à obtenir un **sous-arbre**

→ **Cost complexity pruning**
ou **weakest link pruning**



Élagage

Considérons une séquence d'arbres indexés par un **paramètre de complexité** α
À chaque valeur de α correspond un sous-arbre $T \subset T_0$ tel que :

$$\sum_{m=1}^{|T|} \sum_{x_i \in R_m} (y^{(i)} - \hat{y}_{R_m})^2 + \alpha |T| \quad \text{est minimale}$$

Région de la
 $m^{\text{ième}}$ feuille



Nombre de
feuilles




→ Cette quantité est aussi appelée **Tree Score**

Élagage


$$\sum_{m=1}^{|T|} \sum_{x_i \in R_m} (y^{(i)} - \hat{y}_{R_m})^2 + \alpha |T|$$

α	Tree Score	Tree Score	Tree Score	Tree Score
100		✓		

SSR = 10



SSR = 100



SSR = 500



SSR = 1000




Élagage


$$\sum_{m=1}^{|T|} \sum_{x_i \in R_m} (y^{(i)} - \hat{y}_{R_m})^2 + \alpha |T|$$

α	Tree Score	Tree Score	Tree Score	Tree Score
100	$10 + 100 \cdot 4 = 410$	$100 + 100 \cdot 3 = 400$ ✓	$500 + 100 \cdot 2 = 700$	$1000 + 100 \cdot 1 = 1100$
200	$10 + 200 \cdot 4 = 810$	$100 + 200 \cdot 3 = 700$ ✓	$500 + 200 \cdot 2 = 900$	$1000 + 200 \cdot 1 = 1200$

SSR = 10



SSR = 100



SSR = 500



SSR = 1000




Élagage


$$\sum_{m=1}^{|T|} \sum_{x_i \in R_m} (y^{(i)} - \hat{y}_{R_m})^2 + \alpha |T|$$

α	Tree Score	Tree Score	Tree Score	Tree Score
100	$10 + 100 \cdot 4 = 410$	$100 + 100 \cdot 3 = 400$ ✓	$500 + 100 \cdot 2 = 700$	$1000 + 100 \cdot 1 = 1100$
200	$10 + 200 \cdot 4 = 810$	$100 + 200 \cdot 3 = 700$ ✓	$500 + 200 \cdot 2 = 900$	$1000 + 200 \cdot 1 = 1200$
500	$10 + 500 \cdot 4 = 2010$	$100 + 500 \cdot 3 = 1600$	$500 + 500 \cdot 2 = 1500$ ✓	$1000 + 500 \cdot 1 = 1500$ ✓

SSR = 10



SSR = 100



SSR = 500



SSR = 1000



Question


À votre avis, comment est sélectionnée la valeur du paramètre de complexité α ?

Pour résumer ...

Le paramètre de complexité α contrôle le **compromis entre la complexité du sous-arbre et l'ajustement aux données d'entraînement**

La valeur optimale de α est sélectionnée par **validation croisée**

On construit le sous-arbre final à partir du jeu de données d'entraînement complet basé sur le paramètre de complexité α sélectionné



DecisionTreeRegressor (scikit-learn 0.22.2)

Critère de partition



```
class sklearn.tree.DecisionTreeRegressor(criterion='mse', splitter='best',  
max_depth=None, min_samples_split=2, min_samples_leaf=1,  
min_weight_fraction_leaf=0.0, max_features=None, random_state=None,  
max_leaf_nodes=None, min_impurity_decrease=0.0, min_impurity_split=None,  
presort='deprecated', ccp_alpha=0.0)
```



Paramètre de complexité (pruning)


Sommaire

1. Introduction
2. Arbres de régression
3. Arbres de classification
4. Forces et faiblesses
5. Lectures et références

Arbres de régression (rappel)

Prédiction d'une réponse **quantitative**


Exemple: salaire des joueurs de baseball de la ligue majeure



Arbres de classification

Prédiction d'une réponse **qualitative**


Exemple: présence ou absence d'une pathologie cardiaque (AHD¹)



1 - AHD = Alveolar Hydatid Disease

Arbres de classification

La prédiction pour une observation donnée correspond à la classe la plus fréquente de la région (ou nœud terminal) dans laquelle l'observation se trouve




Arbres de classification

L'arbre de classification est construit par **partitionnement binaire récursif** de l'espace des prédicteurs

À la place du RSS, le partitionnement binaire pourrait se baser sur le **taux d'erreur de classification**

$$E = 1 - \max_k (\hat{p}_{mk})$$

$\hat{p}_{mk}$ est la proportion d'observations appartenant à la classe k dans la région m



Indice de Gini

Est une mesure de la variance totale correspondant aux K classes

$$G = \sum_{k=1}^K \hat{p}_{mk} (1 - \hat{p}_{mk})$$

G est petit lorsque les $\hat{p}_{mk}$ sont proches de 0 ou 1

➔ Assimilé à une mesure de **pureté**

Entropie croisée

Aussi appelé **déviance**

$$D = - \sum_{k=1}^K \hat{p}_{mk} \log \hat{p}_{mk}$$

➔ Très similaire à l'indice de Gini


DecisionTreeClassifier (scikit-learn 0.22.2)

Critère de partition


```
class sklearn.tree.DecisionTreeClassifier(criterion='gini', splitter='best',  
max_depth=None, min_samples_split=2, min_samples_leaf=1,  
min_weight_fraction_leaf=0.0, max_features=None, random_state=None,  
max_leaf_nodes=None, min_impurity_decrease=0.0, min_impurity_split=None,  
class_weight=None, presort='deprecated', ccp_alpha=0.0)
```

Paramètre de complexité (pruning)


Comparaison avec les modèles linéaires



Frontière de
décision linéaire



Modèles linéaires (ex.
Régression logistique)



Frontière de
décision non linéaire



Arbres de décision

Sommaire

1. Introduction
2. Arbres de régression
3. Arbres de classification
4. Forces et faiblesses
5. Lectures et références

Forces

Simplicité et interprétabilité

Faiblesses


Puissance prédictive **limitée**



Mais peuvent être combinés
(Bagging, Boosting, Forêts
aléatoires...) pour obtenir des
performances spectaculaires
Sujet du chapitre suivant !

Sommaire

1. Introduction
2. Arbres de régression
3. Arbres de classification
4. Forces et faiblesses
5. Lectures et références



8 Tree-Based methods
p. 303-336

Gareth James, Daniela Witten, Trevor Hastie and Robert Tibshirani, “An Introduction to Statistical Learning with Applications in R”

Références

[1] Gareth James, Daniela Witten, Trevor Hastie and Robert Tibshirani, “**An Introduction to Statistical Learning with Applications in R**”