16
Machines à vecteurs de support

Automne 2026

Techniques d’apprentissage automatique — 420-C74-SF — gr. 10017
Spécialiste en solutions d’intelligence artificielle — M. Swawola, M.Sc.

NOUS ÉCLAIRONS.
VOUS BRILLEZ.

FORMATION CONTINUE
ET SERVICES AUX ENTREPRISES

Cégep de Sainte-Foy

Sommaire

1. Introduction
2. Intuition
3. Noyaux (kernels)
4. Fonction de coût
5. Mise en oeuvre
6. Lectures et références

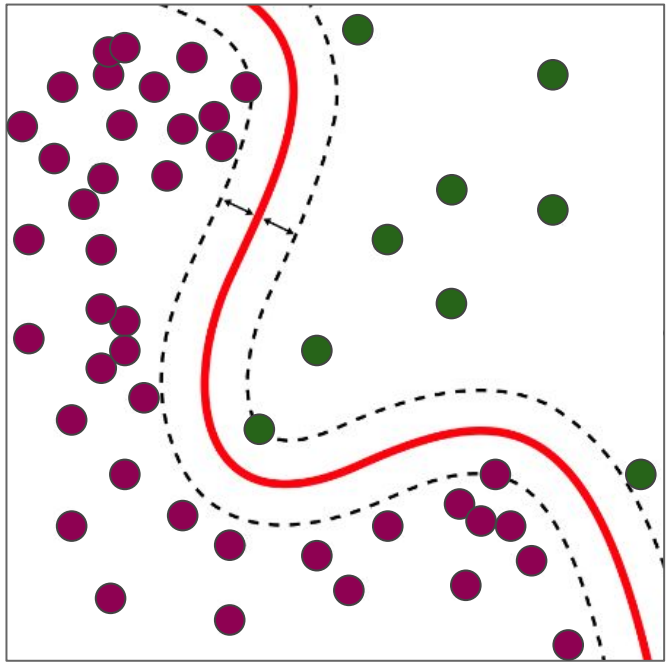
Sommaire

1. Introduction
2. Intuition
3. Noyaux (kernels)
4. Fonction de coût
5. Mise en oeuvre
6. Lectures et références

Introduction

Les machines à vecteurs de support, ou **Support Vector Machines (SVM)**, représentent un type d'algorithme applicable aux problématiques de :

- **Classification**
- Régression
- Détection de données aberrantes (outliers) ou anomalies / nouveautés



→ **Ce cours se limitera aux problématiques de classification**

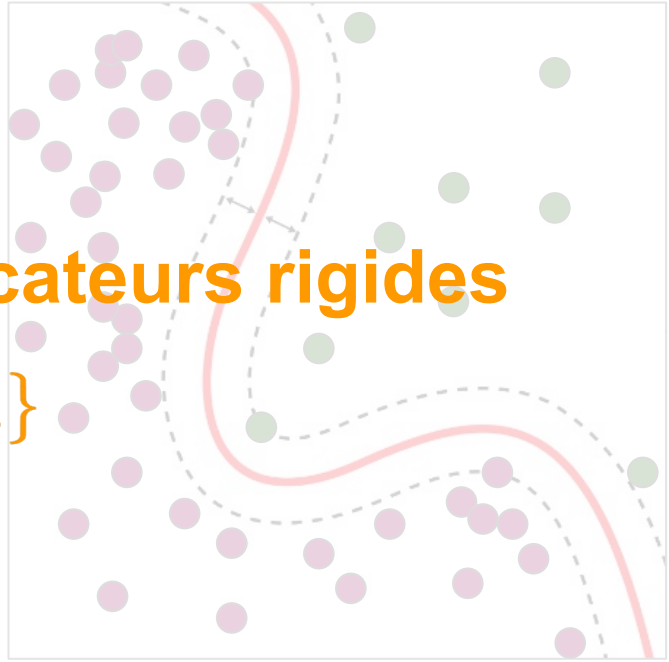
Introduction

Les machines à vecteurs de support, ou **Support Vector Machines (SVM)**, représentent un classe d'algorithmes pouvant résoudre les tâches suivantes :

- **Classification**
- Régression
- Détection de données aberrantes (outliers) ou anomalies / nouveautés

Les SVM sont des classificateurs rigides

$$r : \mathbb{R}^n \longrightarrow \{0, 1\}$$



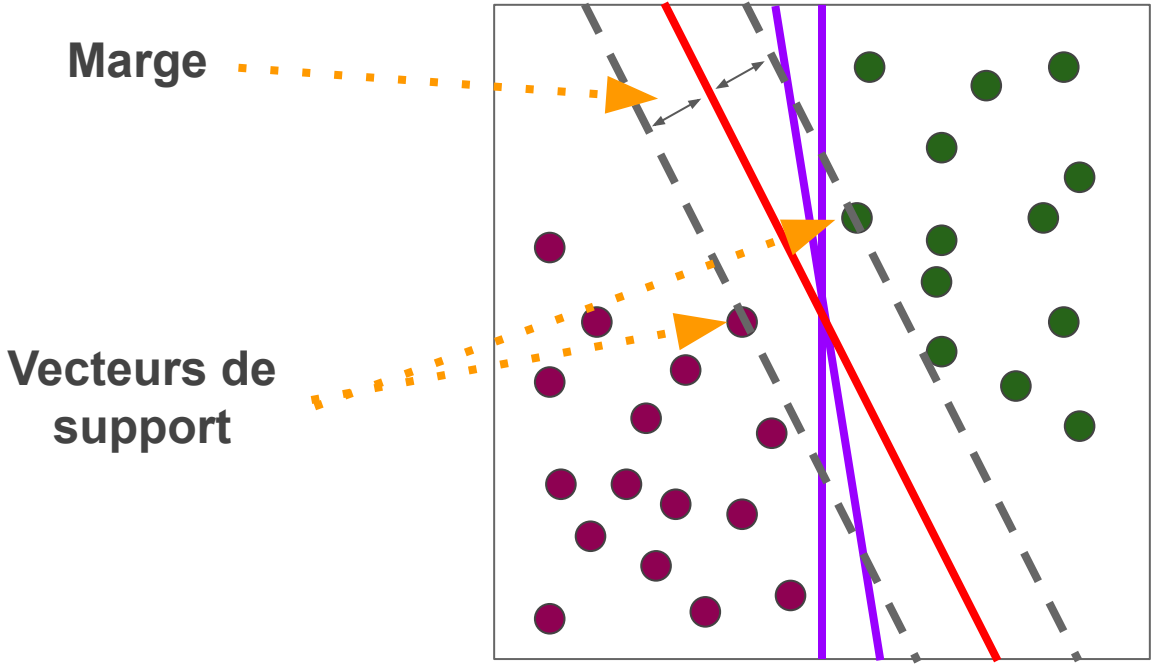
→ **Le cours suivant se limitera aux problématiques de classification**

Sommaire

1. Introduction
2. Intuition
3. Noyaux (kernels)
4. Fonction de coût
5. Mise en oeuvre
6. Lectures et références

Intuition

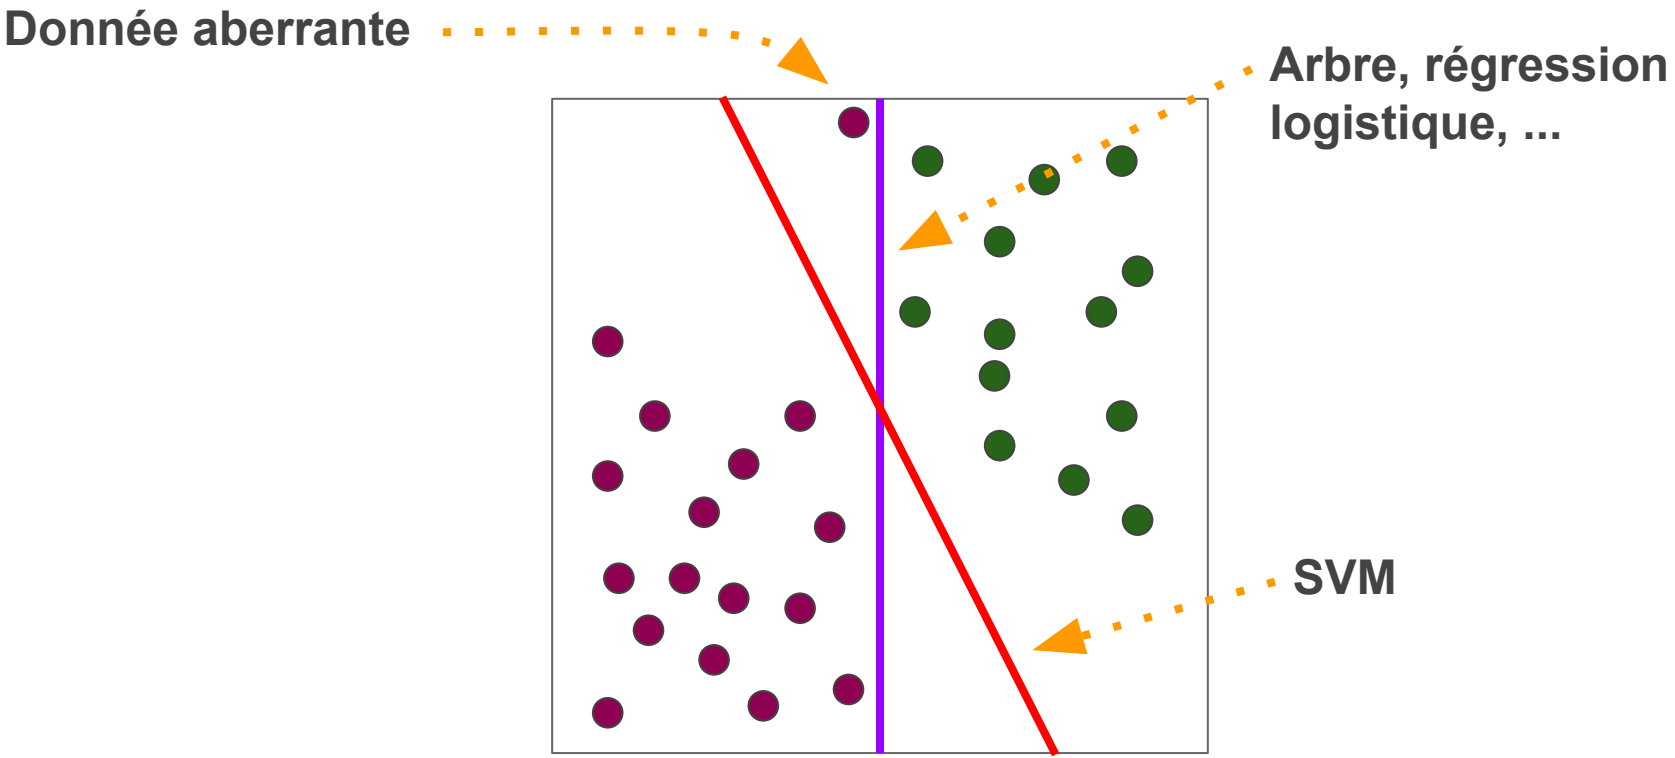
Frontière de décision des SVM (données linéairement séparables)



→ **Séparateur à vaste marge**

Large Margin Classifier

Présence de données aberrantes

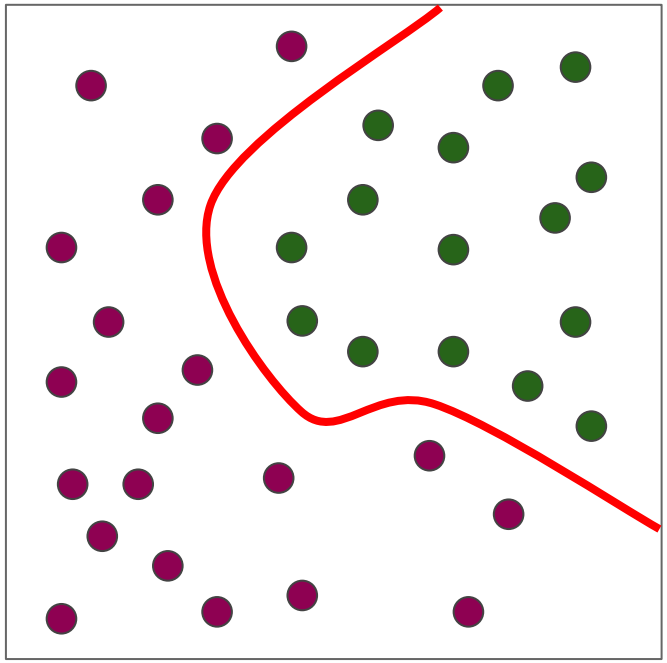


Sommaire

1. Introduction
2. Intuition
3. Noyaux (kernels)
4. Fonction de coût
5. Mise en oeuvre
6. Lectures et références

Noyaux

Frontière de décision non linéaire



En régression logistique, prédiction de $y = 1$ si

$$\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_2^2 + \cdots \geq 0$$

Posons

$$f_1 = x_1, f_2 = x_2, f_3 = x_1^2, f_4 = x_2^2, \cdots$$

L'inéquation ci-dessus peut se réécrire

$$\theta_0 + \theta_1 f_1 + \theta_2 f_2 + \theta_3 f_3 + \theta_4 f_4 + \cdots$$

Noyaux

Frontière de décision non linéaire



En régression logistique, prédiction de $y = 1$ si

$$\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_2^2 + \cdots \geq 0$$

Existe-t-il un meilleur choix de features f_1, f_2, … ?

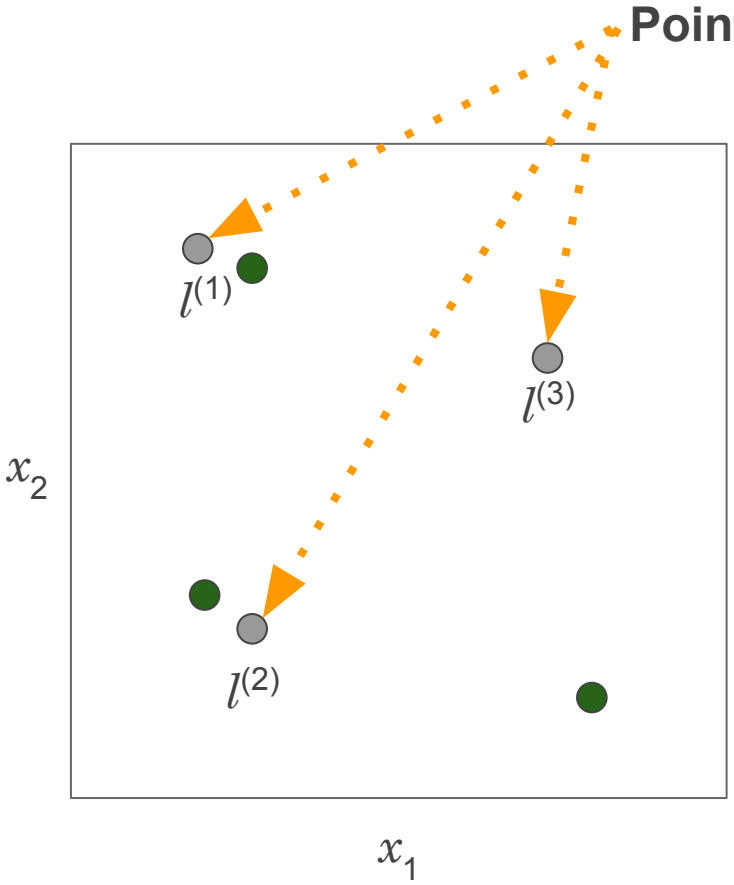
Posons

$$f_1 = x_1, f_2 = x_2, f_3 = x_1^2, f_4 = x_2^2, \cdots$$

L'inéquation ci-dessus peut se réécrire

$$\theta_0 + \theta_1 f_1 + \theta_2 f_2 + \theta_3 f_3 + \theta_4 f_4 + \cdots$$

Noyaux



Les nouvelles features f_1, f_2, … correspondent à la **proximité ou similarité de chaque observation $x^{(i)}$ avec les points de repères $l^{(1)}$, $l^{(2)}$ et $l^{(3)}$**

$$f_1 = \text{similarité}\left(x, l^{(1)}\right)$$
$$f_2 = \text{similarité}\left(x, l^{(2)}\right)$$
$$f_3 = \text{similarité}\left(x, l^{(3)}\right)$$

Noyau

Noyaux

$$f_1 = \text{similarité}\left(x, l^{(1)}\right)$$

$$f_2 = \text{similarité}\left(x, l^{(2)}\right)$$

$$f_3 = \text{similarité}\left(x, l^{(3)}\right)$$

Noyaux

Distance euclidienne

$$f_1 = \text{similarité}\,(x, l^{(1)}) = \exp\left(-\frac{||x - l^{(1)}||^2}{2\sigma^2}\right)$$

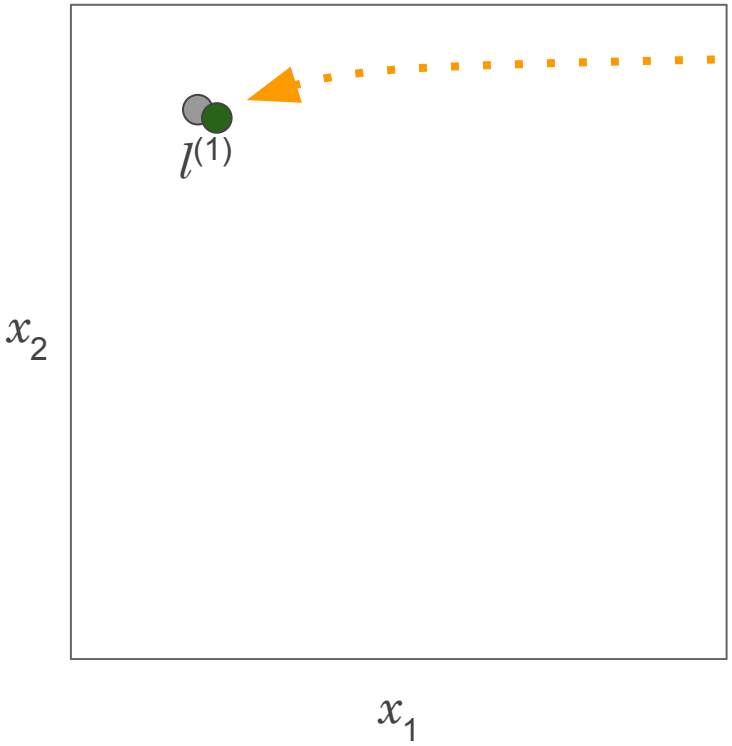
$$f_2 = \text{similarité}\,(x, l^{(2)}) = \exp\left(-\frac{||x - l^{(2)}||^2}{2\sigma^2}\right)$$

$$f_3 = \text{similarité}\,(x, l^{(3)}) = \exp\left(-\frac{||x - l^{(3)}||^2}{2\sigma^2}\right)$$

Noyau gaussien

$k(x, l^{(i)})$

Noyaux

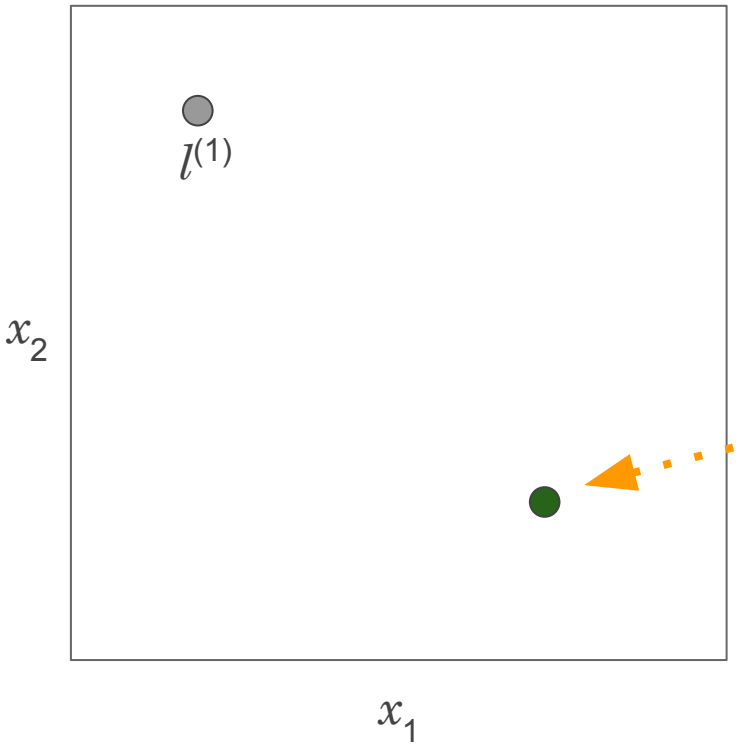


Si x est **proche** du point de repère $l^{(1)}$

$$f_1 = \text{similarité}\,(x, l^{(1)}) = \exp\left(-\frac{||x - l^{(1)}||^2}{2\sigma^2}\right)$$

$$f_1 = \exp\left(-\frac{0^2}{2\sigma^2}\right) \approx 1$$

Noyaux



Si x est **proche** du point de repère $l^{(1)}$

$$f_1 = \text{similarité}\,(x, l^{(1)}) = \exp\left(-\frac{||x - l^{(1)}||^2}{2\sigma^2}\right)$$

$$f_1 = \exp\left(-\frac{0^2}{2\sigma^2}\right) \approx 1$$

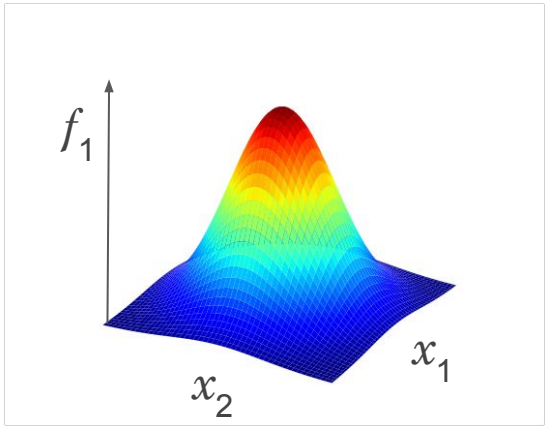
Si x est **éloigné** du point de repère $l^{(1)}$

$$f_1 = \exp\left(-\frac{\text{grand nombre}^2}{2\sigma^2}\right) \approx 0$$

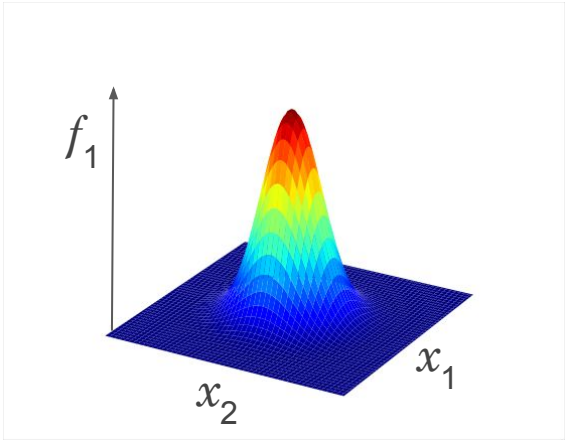
Noyaux

$$f_1 = \exp\left(-\frac{||x - l^{(1)}||^2}{2\sigma^2}\right)$$

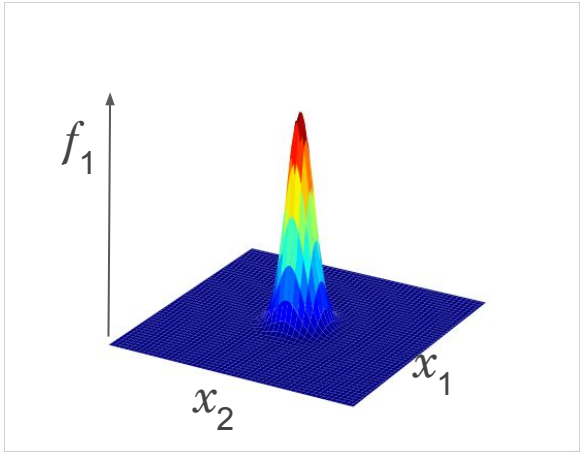
Hyperparamètre



$\sigma^2 = 2$

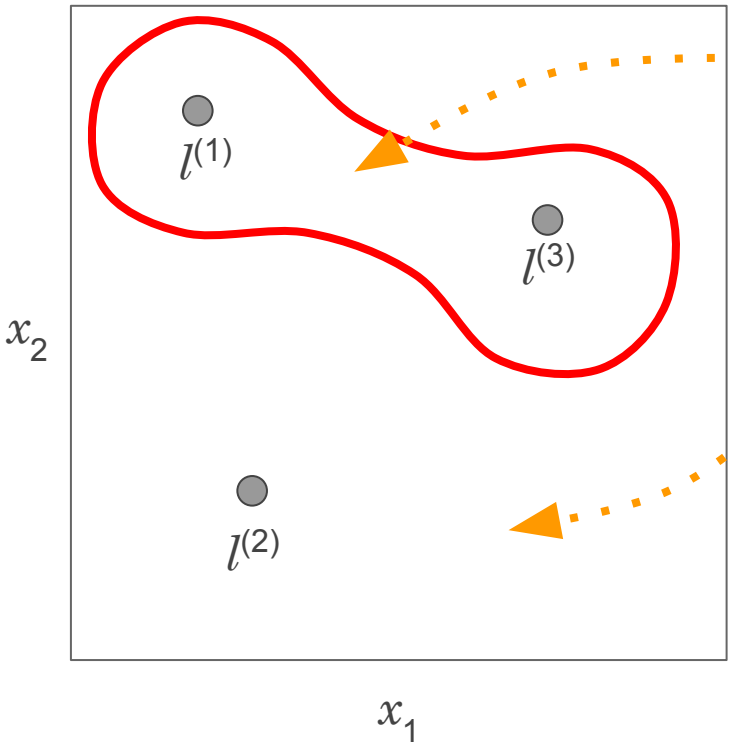


$\sigma^2 = 1$



$\sigma^2 = 0.5$

Noyaux



Prédiction de $y = 1$ si

$$\theta_0 + \theta_1 f_1 + \theta_2 f_2 + \theta_3 f_3 + \theta_4 f_4 + \cdots \geq 0$$

Prédiction de $y = 0$ si

$$\theta_0 + \theta_1 f_1 + \theta_2 f_2 + \theta_3 f_3 + \theta_4 f_4 + \cdots \leq 0$$

La frontière de décision est définie par θ

Noyaux



Prédiction de $y = 1$ si

$$\theta_0 + \theta_1 f_1 + \theta_2 f_2 + \theta_3 f_3 + \theta_4 f_4 + \cdots \geq 0$$

Comment choisir les points de repère $l^{(1)}$, $l^{(2)}$, … ?

Prédiction de $y = 0$ si

$$\theta_0 + \theta_1 f_1 + \theta_2 f_2 + \theta_3 f_3 + \theta_4 f_4 + \cdots \leq 0$$

La frontière de décision est définie par θ

Choix des points de repères

Les points de repères choisis correspondent aux **observations** !

$$l^{(1)} = x^{(1)}, l^{(2)} = x^{(2)}, \cdots, l^{(m)} = x^{(m)}$$

$$f_1 = \text{similarité}\left(x, l^{(1)}\right)$$
$$f_2 = \text{similarité}\left(x, l^{(2)}\right)$$
$$f_3 = \text{similarité}\left(x, l^{(3)}\right)$$
$$\cdots$$

$x^{(i)}$

$$f_1^{(i)} = \text{similarité}\left(x^{(i)}, l^{(1)}\right)$$
$$\cdots$$
$$f_i^{(i)} = \text{similarité}\left(x^{(i)}, l^{(i)}\right)$$
$$\cdots$$
$$f_m^{(i)} = \text{similarité}\left(x^{(i)}, l^{(m)}\right)$$

$x^{(i)}$

Choix des points de repères

Les points de repères choisis correspondent aux **observations** !

$$l^{(1)} = x^{(1)}, l^{(2)} = x^{(2)}, \cdots, l^{(m)} = x^{(m)}$$

$$f_1 = \text{similarité}\,(x, l^{(1)})$$
$$f_2 = \text{similarité}\,(x, l^{(2)})$$
$$f_3 = \text{similarité}\,(x, l^{(3)})$$
$$\cdots$$

$x^{(i)}$

$$f_1^{(i)} = \text{similarité}\,(x^{(i)}, l^{(1)})$$
$$\cdots$$
$$f_i^{(i)} = \text{similarité}\,(x^{(i)}, l^{(i)}) = 1$$
$$\cdots$$
$$f_m^{(i)} = \text{similarité}\,(x^{(i)}, l^{(m)})$$

$x^{(i)}$

Quiz: combien de features a t-on ? $\quad f \in \mathbb{R}^m$

Astuce du noyau ! (kernel trick)

$$\theta^T x = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_3 + \cdots + \theta_n x_n$$

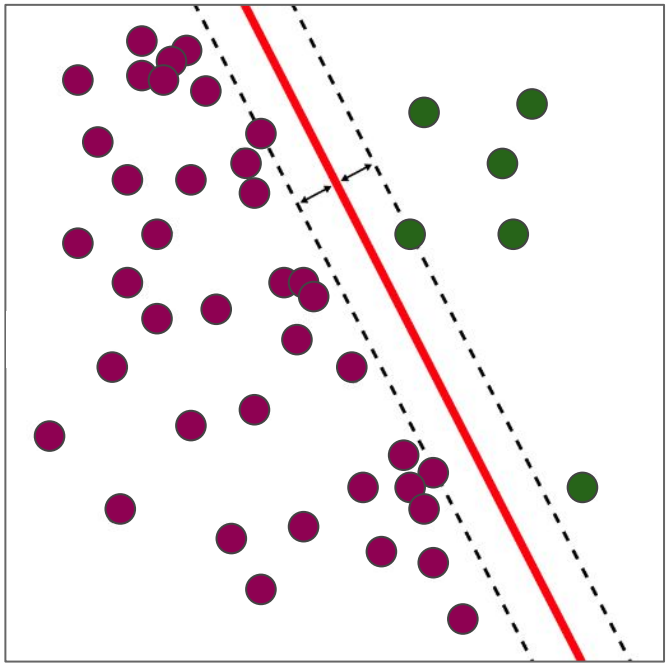


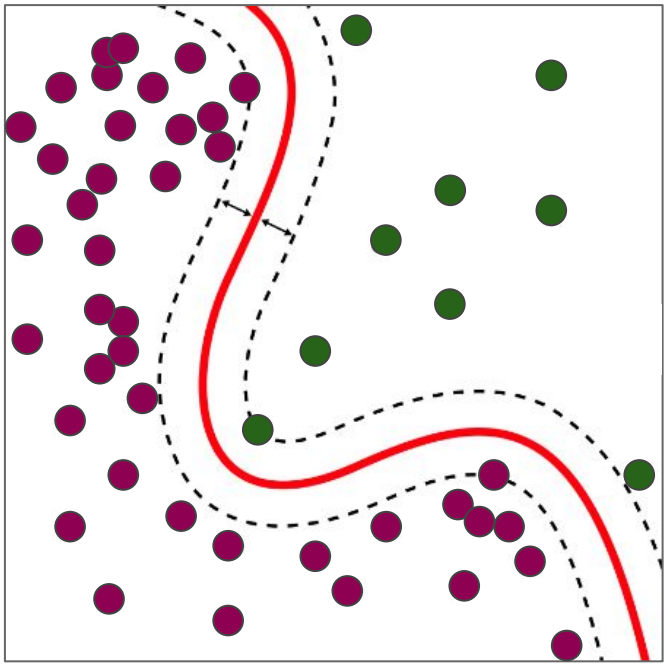
$$\theta^T f = \theta_0 + \theta_1 f_1 + \theta_2 f_2 + \theta_3 f_3 + \cdots + \theta_m f_m$$

Sommaire

1. Introduction
2. Intuition
3. Noyaux (kernels)
4. Fonction de coût
5. Mise en oeuvre
6. Lectures et références

Objectif

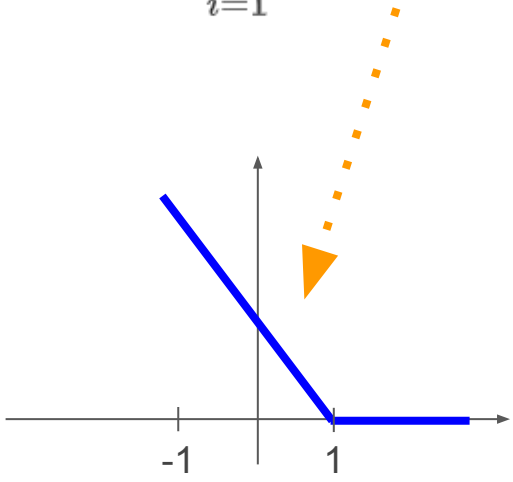


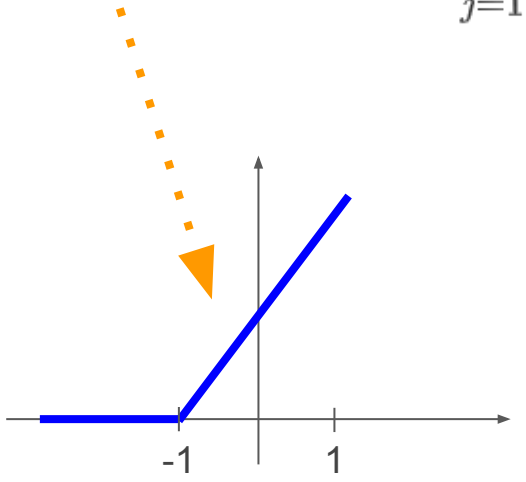


Modèle SVM

$\min_{\theta} J(\theta)$

$$J(\theta) = C \sum_{i=1}^{m} y^{(i)} \text{cost}_1(\theta^T f^{(i)}) + (1 - y^{(i)}) \text{cost}_0(\theta^T f^{(i)}) + \frac{1}{2} \sum_{j=1}^{m} \theta_j^2$$





$y = 1 \rightarrow \theta^T f \geq 1$

$y = 0 \rightarrow \theta^T f \leq -1$

Modèle SVM

$$\min_{\theta} C \sum_{i=1}^{m} y^{(i)} \text{cost}_1(\theta^T f^{(i)}) + (1 - y^{(i)}) \text{cost}_0(\theta^T f^{(i)}) + \frac{1}{2} \sum_{j=1}^{m} \theta_j^2$$

$$h_\theta(f) = \begin{cases} 1 \text{ si } \theta^T f \geq 1 \\ 0 \text{ sinon} \end{cases}$$

Frontière de décision

$$\min_{\theta} C \underbrace{\sum_{i=1}^{m} y^{(i)} \text{cost}_1(\theta^T f^{(i)}) + (1 - y^{(i)}) \text{cost}_0(\theta^T f^{(i)})}_{= 0} + \frac{1}{2} \sum_{j=1}^{m} \theta_j^2$$

$$\min_{\theta} \frac{1}{2} \sum_{j=1}^{m} \theta_j^2$$

Tel que:

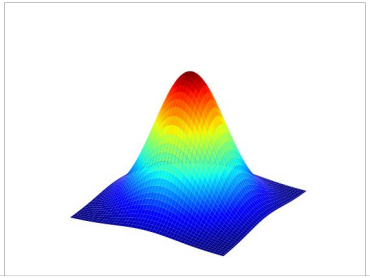
$$\theta^T f^{(i)} \geq 1 \text{ si } y^{(i)} = 1$$
$$\theta^T f^{(i)} \leq -1 \text{ si } y^{(i)} = 0$$

Hyperparamètres

$$\min_{\theta} C \sum_{i=1}^{m} y^{(i)} \text{cost}_1(\theta^T f^{(i)}) + (1 - y^{(i)}) \text{cost}_0(\theta^T f^{(i)}) + \frac{1}{2} \sum_{j=1}^{m} \theta_j^2$$

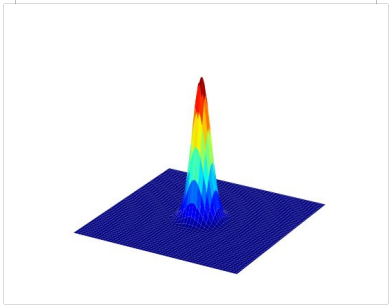
C permet de contrôler le compromis biais / variance

- C élevé: biais faible, variance élevée
- C faible: biais élevé, variance faible



σ^2 permet de contrôler la variation des features f

- σ^2 élevé: biais élevé, variance faible
- σ^2 faible: biais faible, variance élevée



Sommaire

1. Introduction
2. Intuition
3. Noyaux (kernels)
4. Fonction de coût
5. Mise en oeuvre
6. Lectures et références

SVC
(scikit-learn 1.9.1)



*class sklearn.svm.**SVC**(*, **C=1.0**, **kernel='rbf'**, degree=3, gamma='scale', coef0=0.0, shrinking=True, probability='deprecated', tol=0.001, cache_size=200, class_weight=None, verbose=False, max_iter=-1, decision_function_shape='ovr', break_ties=False, random_state=None)*

*Pour classification souple: **CalibratedClassifierCV**(SVC(), ensemble=False)*

Choix des noyaux (kernel)

*class sklearn.svm.**SVC**(C=1.0, **kernel='rbf'**, **degree=3**, **gamma='scale'**, **coef0=0.0**, shrinking=True, probability=False, tol=0.001, cache_size=200, class_weight=None, verbose=False, max_iter=-1, decision_function_shape='ovr', break_ties=False, random_state=None)*

linear

pas de noyau!

RBF

$$\exp\left(-\frac{||x-l^{(1)}||^2}{2\sigma^2}\right)$$

gamma $\left(\frac{1}{2\sigma^2}\right)$

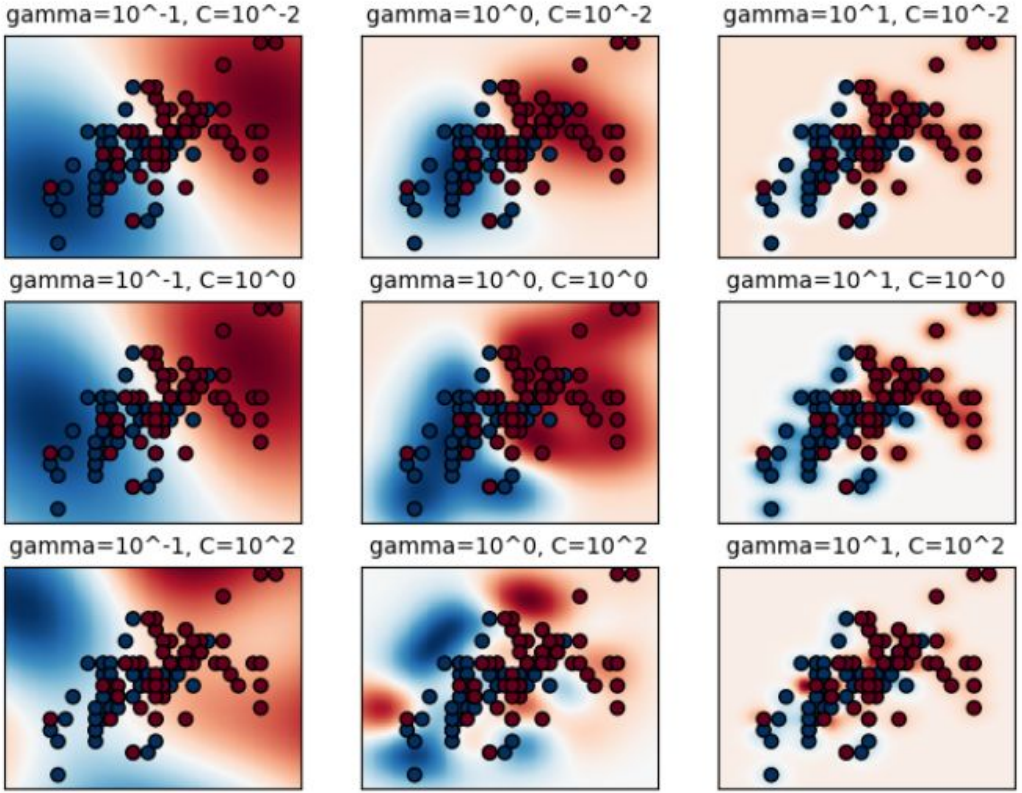
poly

$$(x^T l + c)^n$$

degree (n)
coef0 (c)

→ **Aussi possibilité de kernel custom**

Noyau gaussien et régularisation



Probabilités

Rappel, les SVM sont des **classificateurs rigides** …

Il est possible d'obtenir des **estimés de probabilités calibrés** (Platt scaling)

Le Platt scaling consiste à ajuster une **régression logistique** sur les prédictions du SVM



John C. Platt

SVM vs régression logistique

- **Lorsque $n \geq m$**

  → Régression logistique ou SVM sans noyau

- **Lorsque n est petit et m “intermédiaire”**

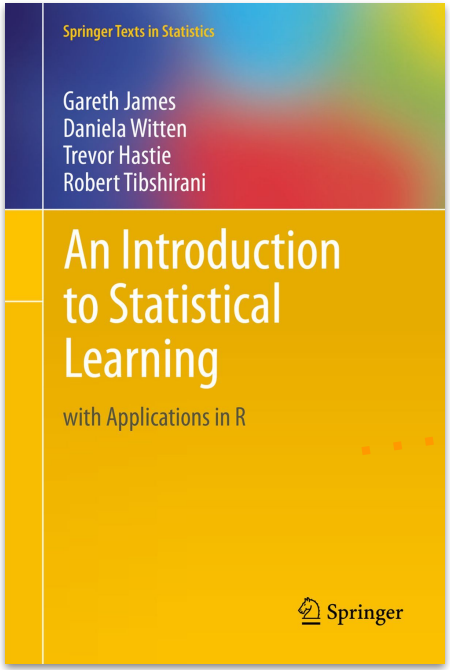
  → SVM avec noyaux gaussien

- **Lorsque n est petit et m grand**

  → ajouter plus de variables prédictives et utiliser une régression logistique ou un SVM sans noyau

Sommaire

1. Introduction
2. Intuition
3. Noyaux (kernels)
4. Fonction de coût
5. Mise en oeuvre
6. Lectures et références



9 Support Vector Machines
p. 337-372

Gareth James, Daniela Witten, Trevor Hastie and Robert Tibshirani, **“An Introduction to Statistical Learning with Applications in R”**

Références

[1] CS229 Machine Learning, Stanford University (Andrew Ng)

[2] Cours “Classification et métriques d’évaluation”, Camille Besse, CRDM